فائزه آزادی

اگر فقط بتوانم سه Feature را برای شروع تحلیل Credit Risk انتخاب کنم، انتخاب من RevolvingUtilizationOfUnsecuredLines، NumberOfTimes90DaysLate و age است.
من این سه Feature را فقط بر اساس Correlation یا یک عدد خاص انتخاب نکردم. بیشتر به این توجه کردم که کدام Feature رابطه واضح‌تری با Default دارد، از نظر Credit Risk قابل‌فهم‌تر است و در کنار بقیه اطلاعات متفاوتی درباره مشتری می‌دهد.
اولین انتخاب من NumberOfTimes90DaysLate است. این Feature نشان می‌دهد مشتری چند بار بیشتر از 90 روز در پرداخت بدهی تأخیر داشته است. بیشتر مشتری‌ها، یعنی حدود 94.61 درصد، هیچ دیرکرد 90 روزه‌ای نداشته‌اند. با این حال، مقادیر غیرصفر خیلی مهم هستند، چون نشان می‌دهند مشتری قبلاً مشکل جدی در بازپرداخت داشته است.
تفاوت بین مشتری‌های Default و No Default در این Feature خیلی واضح است. میانگین آن برای مشتری‌های Default حدود 0.665 است، ولی برای No Defaultها فقط 0.050 است. Default Rate هم با بیشتر شدن تعداد دیرکردها خیلی زیاد می‌شود. برای مشتری‌هایی که هیچ دیرکردی نداشتند، Default Rate حدود 4.63 درصد بود. برای یک دیرکرد این عدد به 33.66 درصد، برای دو دیرکرد به 49.94 درصد و برای سه دیرکرد یا بیشتر به 61.68 درصد رسید. به همین دلیل این Feature برای من مهم‌ترین انتخاب است.
دومین انتخاب من RevolvingUtilizationOfUnsecuredLines است. این Feature نشان می‌دهد مشتری چه مقدار از اعتبار در دسترس خود را استفاده کرده است. در این متغیر چند مقدار خیلی بزرگ وجود دارد، به همین دلیل فقط نگاه کردن به میانگین کافی نیست و Median اطلاعات بهتری می‌دهد.
Median این Feature برای مشتری‌های Default حدود 0.830 و برای No Defaultها حدود 0.133 بود. همچنین با افزایش استفاده از اعتبار، Default Rate هم بیشتر شد. برای utilization بین 0 و 0.25، Default Rate حدود 2.02 درصد بود. این عدد در بازه 0.75 تا 1 به 17.80 درصد و برای مقادیر بالاتر از 1 به 37.26 درصد رسید. بنابراین در این داده، مشتری‌هایی که مقدار بیشتری از اعتبار خود را استفاده کرده‌اند، ریسک Default بیشتری داشته‌اند. البته در این Feature چند مقدار خیلی بزرگ وجود دارد. به همین دلیل برای رسم نمودار فقط نمایش این مقادیر محدود شده است تا نمودار خواناتر باشد، ولی هیچ داده‌ای از دیتاست اصلی حذف نشده است.
سومین Feature که انتخاب کردم `age` است. دلیل انتخاب age این است که نوع متفاوتی از اطلاعات را نسبت به دو Feature قبلی به تحلیل اضافه می‌کند. این Feature هیچ Missing Value ندارد و توزیع آن هم خیلی نامتعادل نیست. Median سن مشتری‌های Default برابر 46 سال و برای No Defaultها 52 سال بود. همچنین Default Rate برای مشتری‌های زیر 30 سال حدود 11.21 درصد بود، در حالی که برای افراد 70 ساله و بالاتر حدود 2.31 درصد بود.
البته این نتیجه به این معنی نیست که سن باعث Default می‌شود. فقط می‌توان گفت در این دیتاست، بین گروه‌های سنی مختلف و Default یک الگو دیده می‌شود. همچنین یک مقدار `age = 0` در داده وجود دارد که احتمالاً یک مشکل کیفیت داده است.
سه Feature دیگر را هم بررسی کردم، ولی برای شروع آن‌ها را انتخاب نکردم.
NumberOfOpenCreditLinesAndLoans در بعضی گروه‌ها تفاوت در Default Rate داشت، ولی الگوی آن به اندازه سه Feature انتخاب‌شده واضح نبود. تعداد حساب‌های بیشتر هم همیشه معنی مشخصی ندارد؛ ممکن است هم نشانه وضعیت اعتباری خوب باشد و هم نشان‌دهنده تعهدات مالی بیشتر.
MonthlyIncome هم Feature مهمی است، چون درآمد می‌تواند با توانایی بازپرداخت بدهی مرتبط باشد. اما حدود 19.77 درصد از مقادیر آن Missing است و رابطه آن با Default از سه Feature نهایی ضعیف‌تر بود.
DebtRatio هم از نظر Credit Risk مهم است، ولی مقادیر خیلی بزرگ و غیرعادی دارد و الگوی آن با Default به اندازه سه Feature نهایی واضح نبود.

همچنین NumberOfDefault را استفاده نکردم، چون این Feature مستقیماً به Target یعنی `SeriousDlqin` مربوط است و ممکن است باعث Data Leakage شود. یعنی ممکن است اطلاعاتی را وارد تحلیل کند که در واقع بخشی از پاسخ نهایی را از قبل نشان می‌دهد.